İçindekiler

1. Optimizasyon Nedir?

Optimizasyon, verilen bir problemin olası çözümleri için çözüm uzayındaki en uygun çözümü belirlemeyi hedefleyen bir disiplindir. Başka bir anlatımla problem için verilen durumlar ve belirli kısıtlamalar altında probleme en uygun çözümün belirlenme sürecidir. Burada her problem için durumlar ve kısıtlamalar farklılık göstermektedir. Olası en iyi çözüm problem içerisinde bulunan tüm olası durum ve kısıtlamaları karşılıyorsa uygun(optimal) çözümdür. Geçmişten günümüze gelene kadar değişik alanlarda kullanılmak üzere probleme uygun farklı optimizasyon teknikleri denenmiştir. Bu teknik ve yöntemler; matematiksel algoritmalar ve sezgisel algoritmalardır. Matematik algoritmaların kullanılmasında sonucunda algoritmaların esnek olmaması ve çözüm uzayı geniş problemlerde tüm çözüm uzayını gezdiği için maliyetinin fazla olması gibi sebeplerden dolayı farklı yüksek performansa, az maliyete ve genel amaçlı kullanabilecekleri yeni yöntem arayışına gidilmiştir. Bu arayış içerisinde doğadaki düzen ve olaylardan esinlenerek farklı optimizasyon yöntemleri geliştirilmiştir. Bu yöntemlere de genel olarak sezgisel yöntemler denmektedir.[1,2]

2. Meta-Sezgisel Yöntemler

2.1 Meta-sezgisel Algoritmalara Giriş

Optimizasyon algoritmalarının konu edindiği gerçek dünya problemleri karmaşık ve sonuca ulaşılması zor olan problemlerdir. Karşılaşılan bu problemlerde genelde kullanılan algoritmalar çözüm odaklı algoritmalar olduğundan bu tür algoritmaları farklı gerçek dünya problemleri üzerinde kullanılamamaktadır. Bu soruna yönelik daha hızlı çalışan ve farklı problemlere uyarlanabilir algoritmalar geliştirilmiştir. Bu algoritmalara metasezgisel algoritmalar denmektedir. Meta-sezgisel kelimesi, yunanca kökenli bulmak anlamına gelen “heurisken” ve üst seviye yöntembilim anlamına gelen “meta” kelimelerinin birleşimi ile ortaya çıkmıştır. Yani üst seviye sezgisel algoritmalar olarak adlandırabiliriz. Meta-sezgisel yöntemler genellikle doğadan esinlenerek tasarlanmış olup farklı problemlere uyarlanabilir. Bu sayede farklı dünya problemlerine karşın sadece amaç fonksiyonunu değiştirmek yeterlidir. Meta-sezgisel yöntemler sezgisel yöntemlerden yararlanarak çözüm uzayını en verimli şekilde kullanmayı hedefler. Bu yöntemler kesin sonuç veremeselerde karmaşık ve büyük problemler için etkin çözümler ortaya koyabilir. Bu nedenle gerçek dünya problemlerinin çözümünde sezgisel algoritmaların aksine meta-sezgisel algoritmalar daha verimlidir.[2,4]

2.2 Meta-Sezgisel Yöntemler

Meta-sezgisel yöntemler problemler için en uygun ya da en uyguna yakın çözümlerin bulunabilmesi için çözüm uzayını daha verimli şekilde kullanmayı ve taramayı hedefler. Bu yöntemler içerisinde birçok farklı teknik içermektedir. Bu teknikler yerel arama algoritmaları ve karmaşık öğrenme süreçleri olabilir. Meta-sezgisel algoritmalar tek bir probleme bağlı kalmadığı için farklı problemler üzerine uyarlanabilir.

Birçok farklı metasezgisel yöntem vardır. Bunlara örnek olarak genetik algoritmalar, parçacık sürü optimizasyonu, tabu araması, karınca kolonisi gibi örnek verilebilir. Bu tekniklerin özellikleri incelendiğinde farklı sınıflandırmalar yapılabilir. Meta-sezgisel yöntemlerin sınıflandırılması şekil 1'deki gibidir.[3]

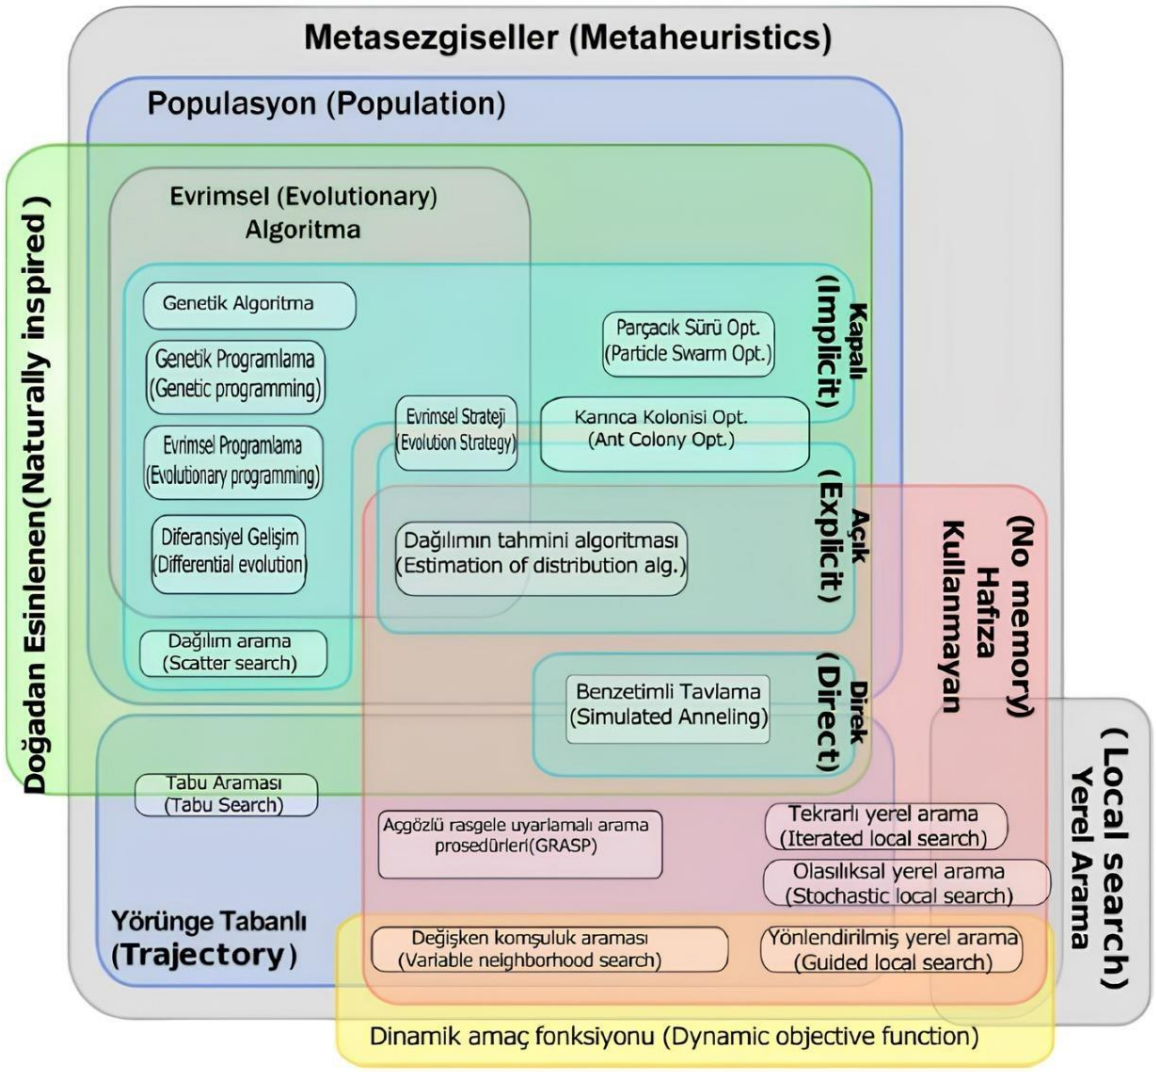

Şekil 1 / Meta-sezgisel Yöntemlerin Sınıflandırılması

Doğadan esinlenilen meta-sezgisel yöntemler, doğada gerçekleşen bir olaydan esinlenerek oluşturulan modeller ile farklı problemlere en uygun çözüm veya çözümleri ortaya koymaya çalışmaktadır. Karınca kolonisi, parçacık sürü optimizasyonu ve genetik algoritmalar doğadan esinlenmiş en bilindik meta-sezgisel yöntemlerdir. Tabu arama ve yinelemeli yerel arama ise doğadan esinlenmeyen metasezgisel yöntemler arasında yer almaktadır. Dinamik amaç fonksiyonlarında çözüm arayışı içerisinde iken amaç fonksiyonu dinamik olarak değiştirilebilmektedir. Bunun amacı yerel en iyi arama sonuca takılı kalınmadan global en iyi arama sonucunun bulunmasını sağlamaktır. Meta-sezgisel yöntemlerin diğer bir sınıflandırma çeşidi de komşuluk yapılarına göre sınıflandırmadır. Meta-sezgisel yöntemlerin büyük bir kısmı komşuluk yapısına sahip algoritmalar olarak geçmektedir. Bu metasezgisel yöntemler komşuluk yapısını kullanarak aramalarda çeşitlilik kazanılmasını sağlar. Meta-sezgisel

yöntemlerin bir diğer sınıflandırma çeşidi de yöntemlerin hafıza kullanıp kullanmadığına göre yapılan sınıflandırmadır. Tabu araması, parçacık sürü optimizasyonu, genetik algoritma ve karınca kolonisi algoritmaları hafıza kullanan metasezgisel yöntemlerdir. Hafıza kullanılan algoritmalar probleme yönelik çözüm aşamalarında tespit edilen en uygun sonuçların daha sonraki aşamalarda kullanılmak üzere hafızada saklanır. Bu nedenle bu algoritmalara hafıza kullanılan metasezgisel algoritmalar denmektedir.[4]

Farklı sınıflandırmalarda mevcuttur. Şekil 2'de farklı bir sınıflandırmaya ait tablo gösterilmiştir. Bu sınıflandırma esas alınan durum çözüm sayısına yönelik olarak incelenmiştir. Tek çözüme dayalı yöntemler, problem üzerinde ki arama sürecini tek bir çözüm ile gerçekleştirir. Toplum tabanlı algoritmalarda ise her aramada bir çözüm uzayı kullanarak ilerler.

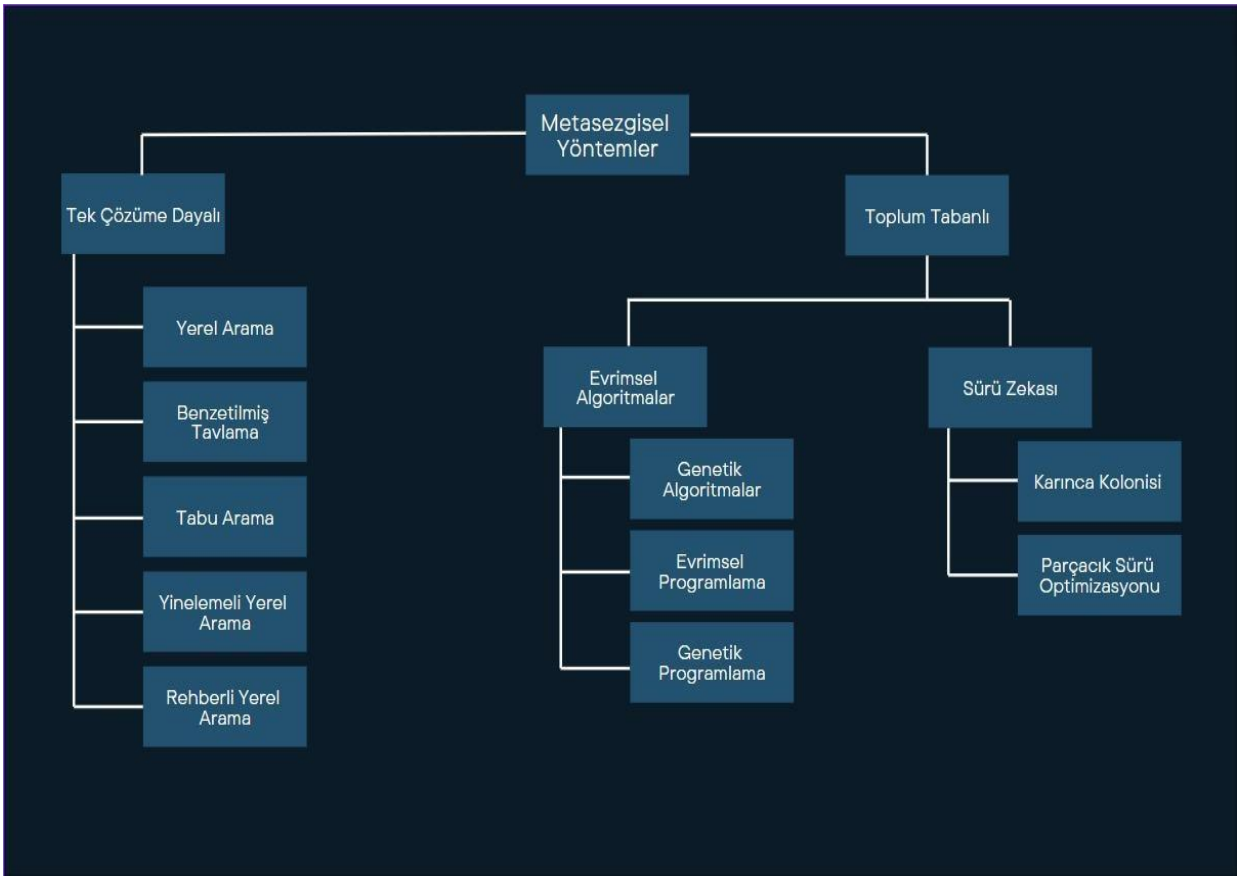

Şekil 2/ Meta-sezgisel Yöntemlerin Çözüm Sayısına Dayalı Sınıflandırılması

2.2.1 Tek Çözüme Dayalı Yöntemler

Tek çözüme dayalı metasezgisel yöntemler, başlangıçta tek bir çözüm ile başlar ve devamında arama uzayında tek çözüme bağlı kalarak diğer olası çözümleri ilk başta oluşturulan tek çözümü referans alarak çözümü araştırır ve uygun olan çözümü seçer. Bu çözüm arayışını genel de ilk başta oluşturulan çözümün komşuluklarını tarayarak gerçekleştirir. Bu yöntemde bazı ortak

kavramlar vardır; komşuluk, yerel optimum ve ilk çözüm. Tek çözüme dayalı meta-sezgisel yöntemlerde ki en önemli faktör komşuluk tanımlanmasıdır. Bu komşuluğun tanımlanması algoritmanın performansına ve maliyetinde önemli bir yer edinmektedir. Komşuluk tanımlamasının yeterli olarak yapılmadığı algoritmalarda problem ya çözüme ulaştırılamaz ya da çözüm yetersiz kalacaktır. Bu yöntemde komşuluk yapısının büyük seçilmesi çözüm kalitesine olumlu bir etkisi olurken hesaplama süresinde ciddi bir oranda artışa sebep olmaktadır. Çözüm kalitesi ve hesaplama süresi arasında ters orantı vardır.[5]

2.2.2. Toplum Tabanlı Yöntemler

Toplum tabanlı metasezgisel algoritmalar tek çözüme dayalı algoritmaların aksine tek bir çözüme bağlı kalmayıp her yinelemede oluşturduğu çözüm kümesi üzerinden kendini geliştirerek arama yapan algoritmalardır. Bu metasezgisel yöntemle oluşturulan arama uzayının daha realistik bir yapıda araştırılmasına olanak tanır. Toplum tabanlı algoritmaların performans ölçütü toplumun veya herhangi bir popülasyonun birbiri arasında ki uyuma bağlıdır. Bu toplum tabanlı yöntemler 2 ye ayrılır. Bunlar; evrimsel algoritmalar ve sürü zekasıdır. Doğadan esinlenilen sürü zekâsı içerisinde; Parçacık sürü optimizasyonu, karınca kolonisi gibi algoritmalar yer alırken Genetik algoritmalar, Evrimsel programlama ve genetik programlama algoritmaları da Evrimsel algoritmalar kapsamında incelenmektedir.[6]

3. Parçacık Sürü Optimizasyonu (PSO)

3.1 Parçacık Sürü Optimizasyonu Tarihi

Parçacık sürü optimizasyonunun temel fikri 1987 senesinde Reynolds tarafından yapılmış kuş sürülerinden ilham alınarak benzer parçacıkların modellenmesi üzerine yapmış olduğu çalışmalar sonucunda ortaya çıkmıştır. Bu yapılan çalışmada sürü de ki her bireyin hareketleri önceki nesilden gelen genlerinde saklı olduğu bilgisine dayanarak bu teknik oluşturulmuştur.[7]

Eberhart ve Kennedy sürü olarak hareket eden hayvan popülasyonlarının yiyecek bulmak veya göç etmek gibi davranışlar içerisindeyken ortaya koydukları hareketlerin aynı popülasyon içerisindeki bireyleri etkilediğinin ve popülasyonu hedefledikleri noktaya ya da yiyeceğe daha kolay ulaşabildiklerini gözlemleyip modellemişlerdir. Eberhart ve Kennedy 1995 yılında dayanarak bu modellemelerin optimizasyon problemlerinin çözümü veya olası çözüm potansiyelini fark edip bu konuya daha da yoğunlaşarak parçacık sürü optimizasyonu tekniğini ortaya koymuştur. Şekil 3'te Esinlenilen davranışlar ve algoritmada karşılık gelen eylemler belirtilmiştir. [8,9]

Esinlenen Davranışlar	Algoritmada Karşılık Gelen Eylem
1.Kuşlara rastgele konumları ve hızları belirlenir. Bu konumların besin kaynaklarına yakınlığı hesap edilir.	1.Rastgele çözüm kümeleri oluştur. Her çözüm kümesi parametre sayısı kadar eleman içerir. Oluşturulan çözüm kümelerinin uygunluk değerleri bulunur.
2. Kuşlar konumlarını sürüde en iyi konuma sahip kuşa ve geçmişteki kendi en iyi konumlarına bir hız belirlerler. Belirlenen hızla birlikte kuş konumunu yeniler.	2. Tüm çözüm kümelerine sırayla iyileştirilme formülü uygulanır.
3. Belirlenen tekrar sayısına ulaşıncaya kadar 2. Aşamaya geri dönülür.	3. Maksimum iterasyona ulaşıncaya kadar 2. Aşamaya geri dönülür.

Şekil 3/ Esinlenilen Davranışlar

3.2 Parçacık Sürü Optimizasyonu Nedir?

Parçacık sürü optimizasyonu parçacıklar arası bilgi aktarımı sağlanan toplumsal tabanlı bir metasezgisel algoritmadır. Bu bilgi aktarımını kuş sürülerinin yemek arayışı esnasında sürüye üye olan her kuşun yemek arayışı içinde oldukları alanda rastgele dağılması ve her bir kuşun arama alanında arayışı bittiğinde eş zamanlı olarak bir araya gelerek yiyeceğin nerede olduğu hakkında bilgi paylaşımında bulunurlar. Sürü içerisinde ki kuşlar yemeğin ne kadar uzaklıkta olduğunu ve yemeğe en yakın olan kuşun konumunu belirler. Bu sayede sürüde ki kuşlar da yiyeceğe doğru yönelirler. Bu hareket Parçacık sürü optimizasyonun parçacıklar arası bilgi aktarımını açıklayan bir harekettir. Parçacık sürü optimizasyonu bu senaryo referans alarak oluşturulmuş ve çalışma mantığı bu senaryo üzerinden açıklanmaktadır. [9]

3.3 Parçacık Sürü Optimizasyonu Algoritması ve Çalışma Prensibi

Bu teknikte sistem popülasyonda ki parçacıklara rastgele potansiyel çözümler vererek başlatır. Popülasyonda bulunan her parçacık kendinden bir önceki parçacığın deneyiminden faydalanarak kendi pozisyonunu en iyi pozisyona göre ayarlar. Parçacık sürü optimizasyonunda parçacıklar kendi arasında haberleşerek en iyi konumdaki parçacığa yaklaşmayı hedefler. Bu teknikte her parçacık yeni iterasyonda bir önceki kendi konuma göre daha iyi bir konuma gelir ve bu konum değişikliğini en iyi konuma gelene süreci devam ettirir. Şekil 4'te parçacık sürü optimizasyonunun akış şeması verilmiştir.[10,11]

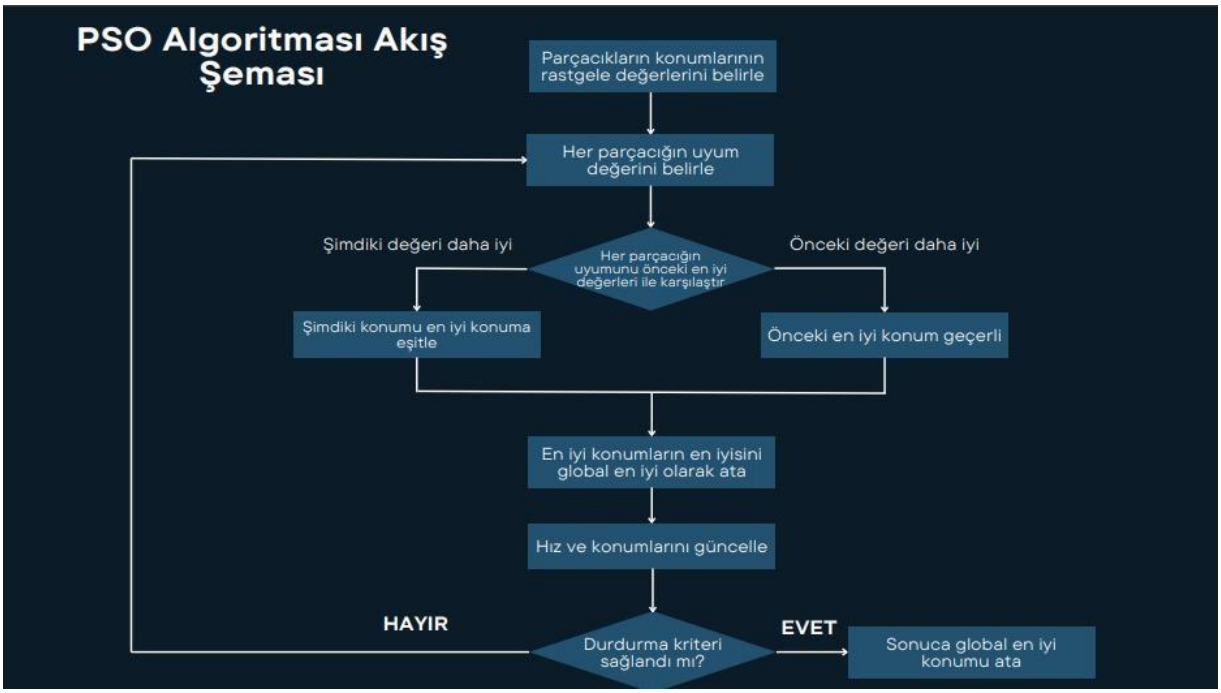

Şekil 4 / Algoritma Akış Diyagramı

Akış diyagramındaki hız ve konum güncellemesi adımı belirli bir denkleme sahiptir. Bu denklemin matematiksel ifadesi aşağıdaki gibidir.

$$V_{id} = W * V_{id} + c_1 * rand_1 * (P_{id} - X_{id}) + c_2 * rand_2 * (P_{gd} - X_{id})$$

$$X_{id} = X_{id} + V_{id}$$

Belirtilen formülde parçacıkların hareketleri sürü içerisindeki konumlarına(x), hızlarına(v) ve ataletlerine bağlı olarak hesaplanmaktadır. Formüldeki değişkenlerin detaylı açıklamaları, ne işe yaradığı ve performansa etkisi aşağıda açıklanmıştır.

3.3.1 Atalet (W)

Atalet terimi parçacıkların hareket yönünü koruma ve değiştirme derecesini değiştirir. Atalet bir parçacığın hareket durumunun değişmesine karşı gösterdiği direnci ifade eder. Atalet değerinin düşük olması parçacığın rastgele hareket etme eğilimini azaltır. Düşük atalet parçacıkları daha fazla yerel aramaya yönlendirir yani daha önce keşfedilen iyi çözümlere daha fazla yönelir. Atalet değerinin yüksek olması ise rastgele hareket etme eğilimini arttırır ve daha fazla global aramaya yönlendirir. Yani daha geniş bir arama uzayına sahip olur.[10,11]

3.3.2 Pbest ve Gbest

Parçacık sürü optimizasyonunda ki parçacıklar iki farklı hareket eğilimi göstermektedir. Bunlar pbest ve gbest'tir. Gbest değeri sürü içerisindeki tüm parçacıkların en iyi konuma yaklaşma eğilimi olarak açıklanabilir. Pbest ise sürü içerisindeki tek bir parçacığın kendisine ait en iyi konumu koruma eğilimi olarak açıklanabilir.

İlk Pbest değeri arama işlemine başlamadan önce rastgele verilmiş başlangıç konumlarına eşittir. Her iterasyonda bir önceki pbest değeri ile kıyaslanarak yeni pbest değerini günceller. Parçacıklar bu tarama esnasında en iyi pbest değerini bulmayı amaçlar.

Sürü içerisindeki tüm parçacıkların arasından seçilen en iyi pbest değeri en iyi gbest değeri olarak seçilir. Her iterasyonda gbest değeri de kıyaslanarak güncellenir.[12]

3.3.3 Random (rand)

Sürü içerisindeki parçacıkların boyutları parçacıkların problemin sonuçlarını etkilemektedir. Bu nedenle parçacıkların boyutları PSO algoritmasında önemli bir yere sahiptir. Verilecek random boyut değeri [0,1] değer aralığına sahiptir.[12,13]

3.3.4 C Sabiti

C sabiti sürü içerisindeki parçacıkların konumlarını ve yayıldıkları alanı etkilemektedir. C değerinin düşük olması parçacıkların daha dar alana yayılmasına, c değerinin yüksek olması parçacıkların daha geniş alana yayılmasına neden olur. C değeri problemin durumuna göre [0,2] aralığında alınır. C değerinin yüksek olması verilen problemin çözümünde optimum sonucun verilmesini sağlar.[14]

3.3.5 Konum (x)

Parçacık sürü optimizasyonu algoritmasında sürü içerisinde bulunan parçacıkların konumu başlangıçta rastgele olarak atanmaktadır. Verilecek bu rastgele değerler belirli koşullara bağlıdır ve bunun neticesinde parçacıkların sapması azalmaktadır. Her parçacığın konumu her iterasyonda bir önceki konumlarına ve o anki hızlarına bağlı olarak belirlenmektedir.[13]

3.3.6 Hız (v)

PSO algoritmasındaki parçacıkların o anki hızları bir sonraki adımda yeni oluşturulacak olan parçacıkların konum ve hızının belirlenmesinde önemli bir yere sahiptir. [12]

3.4 Kullanıldığı Alanlar

Parçacık sürü optimizasyonu günümüzde farklı alanlarda kullanılmaktadır. Bunlara örnek olarak; Atölye tipi çizelgeleme, yapay sinir ağları, tasarım, çizelgeleme problemleri, veri madenciliği ve biyoenformatik gibi alanlarda kullanılır. Bu problemlere uygun optimum çözümleri verir. Her problem için kesin çözüm verme garantisi yoktur.[13]

3.5 PSO Fonksiyon Problemi Çözüm Örneği

Bu örneğimizde bize verilen fonksiyon denkleminin sonucunu 0 yapacak değeri bulmak amaçlanmaktadır. Bu örnekte kullanılacak olan fonksiyon denklemi aşağıda verilmiştir:

$$\boldsymbol{f(x) = x^2 + 2x - 3}$$

Bu fonksiyon denklemini PSO Algoritması ile çözerken öncelikli olarak parçacık sayısı belirlenmelidir. Bu örnekte parçacık sayısı 3 olarak belirlenmiştir. Parçacık değerleri sırasıyla 3, 7 ve 6 olarak belirlenmiştir.

$$\boldsymbol{P_1 = 3,\ P_2 = 7,\ P_3 = 6}$$

Bu örnekteki amacımız problemin denklemini 0'a yaklaştırmak olduğundan uygunluk fonksiyonumuz problemin denkleminin ta kendisidir.

$$\boldsymbol{f(3) = 12,\ f(7) = 60,\ f(6) = 45}$$

Bundan sonraki adımda önceden verilmiş olan PSO denkleminde yerine koyma işlemi yapılacaktır. Denklemde bulunan atalet değeri 1 olarak belirlenmiş olup denklem içerisinde bir etkiye sahip olmayacağından denklem içerisinde gösterilmemiştir. Denklemdeki c1, c2, rand1 ve rand2 değeri hesaplama kolaylığı açısından 2 olarak belirlenmiştir. İlk iterasyonda bulunduğumuzdan dolayı Pbest değerleri parçacıkların kendi değerleridir. Gbest değeri ise 0'a en yakın değere sahip olan parçacık değeri belirlenir. Bu fonksiyon denkleminde Gbest değeri ilk parçacığın değeri olan 3 değeri olarak belirlenmiştir. Denklemde bulunan hız değeri ise daha ilk iterasyonda bulunduğumuzdan dolayı herhangi bir hıza sahip değildir. Bu sebeple ilk değişim hızını 0 olarak kabul ediyoruz. Verilen değerler neticesinde aşağıdaki örneklerde parçacıkların değişim hızları hesaplanmıştır.

$$\boldsymbol{P_1 = 0 + 2 * 2 * (3 - 3) + 2 * 2 * (3 - 3) = 0}$$
$$\boldsymbol{P_2 = 0 + 2 * 2 * (7 - 7) + 2 * 2 * (3 - 7) = -16}$$
$$\boldsymbol{P_3 = 0 + 2 * 2 * (6 - 6) + 2 * 2 * (3 - 6) = -12}$$

Bu işlemler sayesinde parçacıkların her birinin değişim hızları bulundu. Aşağıdaki aşamada başlangıçtaki parçacıklar değişim değerleri ile toplanarak yeni parçacık değerleri belirlenir.

$$\boldsymbol{P_1 = 3 + 0 = 3}$$
$$\boldsymbol{P_2 = 7 - 16 = -9}$$
$$\boldsymbol{P_3 = 6 - 12 = -6}$$

Yeni parçacık değerlerini kullanarak 0'a ne kadar yaklaştığımızı tekrar değerlendirmek gerekir. Yeni parçacıkların uygunluk değerleri bulunur.

$$\boldsymbol{f(3) = 12,\ f(-9) = 34,\ f(-6) = 21}$$

İlk iterasyonda istenilen sonuca ulaşılamamıştır. Bundan dolayı iterasyona devam edilmelidir. Aynı işlemler ikinci iterasyonda da yapılacaktır. İkinci iterasyonda pbest'ler parçacıkların yeni değeri olacaktır. Yeni Gbest değeri ise tüm pbestlerin en iyi değeri olan 3'tür. Diğer sabit değerler ise aynı kalacaktır.

İkinci iterasyona başlarken parçacık değerleri ve uygunluk değerleri önceki aşamada zaten belirlenmişti. Parçacıkların yeni değeri ve uygunluk fonksiyonları tekrar aşağıda gösterilmiştir.

$$\boldsymbol{P_1 = 3,\ \ P_2 = -9,\ \ P_3 = -6}$$

$$\boldsymbol{f(3) = 12,\ \ f(-9) = 34,\ \ f(-6) = 21}$$

İkinci iterasyonun diğer adımında ise parçacıkların yer değiştirme hızları hesaplanacaktır.

$$\boldsymbol{P_1 = 0 + 2 * 2 * (3 - 3) + 2 * 2 * (3 - 3) = 0}$$
$$\boldsymbol{P_2 = 0 + 2 * 2 * (-9 - (-9)) + 2 * 2 * (3 - (-9)) = 48}$$
$$\boldsymbol{P_3 = 0 + 2 * 2 * (-6 - (-6)) + 2 * 2 * (3 - (-6)) = 36}$$

Bu işlemler sonucunda parçacıkların değişim hızları bulunmuştur. Sıradaki adımda parçacıkların değişim hızları ile önceki parçacık değerleri ile toplanarak yeni parçacık değerleri bulunur.

$$\boldsymbol{P_1 = 3 + 0 = 3}$$
$$\boldsymbol{P_2 = -9 + 48 = 39}$$
$$\boldsymbol{P_3 = -6 + 36 = 30}$$

Yeni parçacık değerlerinı kullanarak 0'a ne kadar yaklaştığımızı tekrar değerlendirmek gerekir. Yeni parçacıkların uygunluk değerleri bulunur.

$$\boldsymbol{f(3) = 12,\ \ f(39) = 1596\,, f(30) = 957}$$

İkinci iterasyon sonucunda da 0 değeri bulunamamıştır. 0 değeri bulunana kadar iterasyonlar devam edecektir. Birinci ve ikinci iterasyondaki işlemler diğer iterasyonlarda da aynı adımlar ile yapılmalıdır.[12]

3.6 PSO Uygulama Örneği

Çalışmanın Amacı: Matematiksel bir fonksiyonun maksimum değerini veren x değerini bulmak

Yöntem: Parçacık sürü optimizasyonu (PSO)

Programlama Dili: Python

Kullanılan Kütüphaneler: tkinter, random

Kod Akış Diyagramı

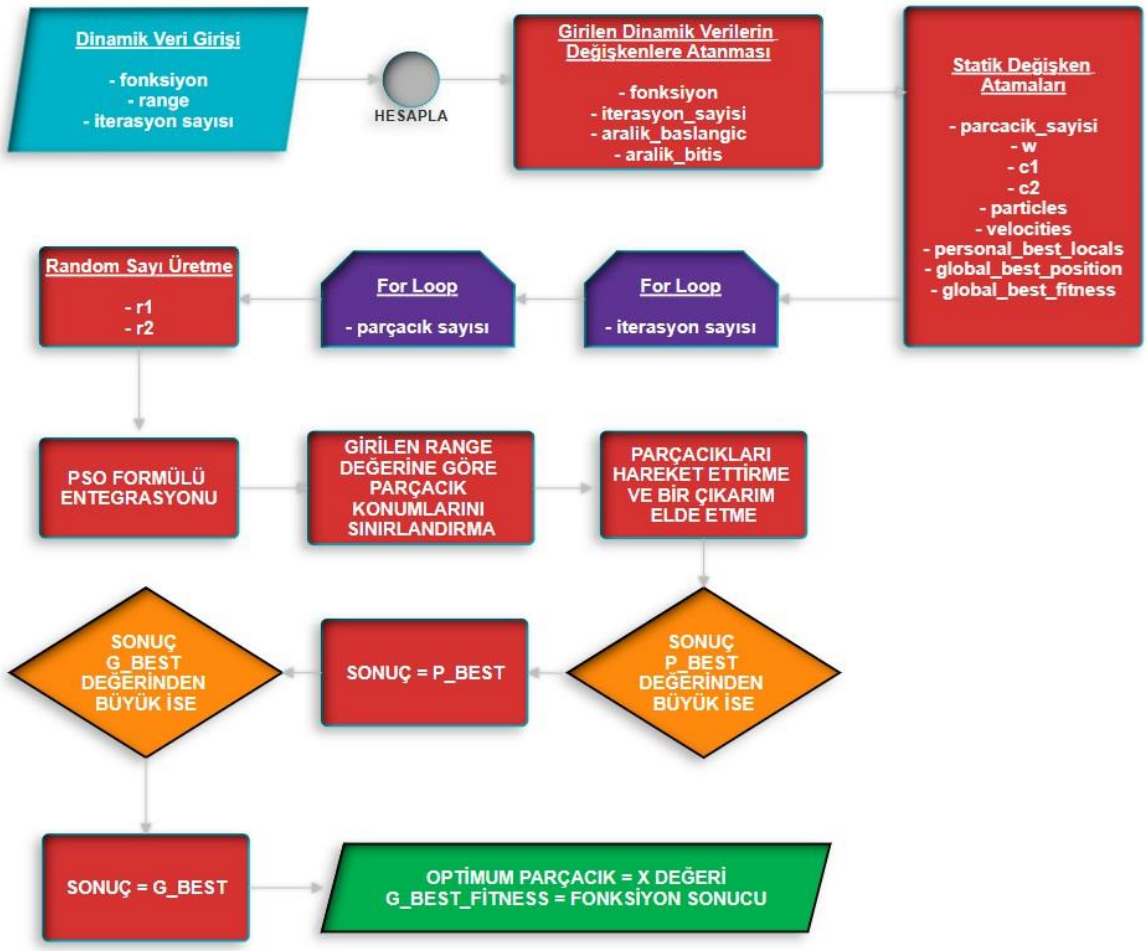

Şekil 5 / PSO Kod Diyagramı

```
import tkinter as tk
import random


def hedef_fonksiyon(parcacik): #textbox'a girilecek x degeri parametre olarak alindi, bu x degerinde parcaciklar denenerek optimum sonuca ulasilmasi hedeflenmektedir

    try:
        fonksiyon = textbox_fonksiyon.get()
        result = eval(fonksiyon, {'x': parcacik})
        return result
    except ZeroDivisionError:
        result2 = eval(fonksiyon, {'x': parcacik + random.random()})
        return result2

def pso():

    parcacik_sayisi = 20

    #kullanicidan alinan parametreler
    iterasyon_sayisi = int(textbox_iterasyon.get())
    aralik_baslangic = int(textbox_min.get())
    aralik_bitis = int(textbox_max.get())

    w = 0.7 # agirlik faktoru
    c1 = 0.5 # sabit degerler
    c2 = 0.3

    particles = []
    velocities = []

    # parcacik sayisi kadar verilen aralikta parcaciklar olusturma
    for i in range(parcacik_sayisi):
        particles.append(random.uniform(aralik_baslangic, aralik_bitis))

    for i in range(parcacik_sayisi):
        velocities.append(0)

    personal_best = particles # parcaciklarin son konumlarini guncellemek icin olusturulan kopya array
    global_best = particles[0] # tum parcaciklarin icindeki en iyi konum
    global_best_fitness = hedef_fonksiyon(particles[0]) #g_best degerinin fonksiyona yerlestirilmesi

    #onceki iterasyonlari temizleme
    text_islemler.delete("1.0", tk.END)

    for iterasyon in range(iterasyon_sayisi):

        for i in range(parcacik_sayisi):

            #0-1 araliginda random sayilar uretme
            r1 = random.random()
            r2 = random.random()

            #PSO FORMULU
            #parçacığın hızını belirleme
```

```
            velocities[i] = w * velocities[i] + c1 * r1 * (personal_best[i] -
particles[i]) + c2 * r2 * (global_best - particles[i])
            #parçacığın değerini güncelleme
            particles[i] = particles[i] + velocities[i]

            #parcaciklarin konumunu verilen aralikta tutma
            if particles[i] < aralik_baslangic:
                particles[i] = aralik_baslangic

            if particles[i] > aralik_bitis:
                particles[i] = aralik_bitis

            #parcacigi matematiksel fonksiyonda x yerine yazip sonuc degerini alma
            fonksiyonun_sonucu = hedef_fonksiyon(particles[i])

            #fonksiyonun sonucunu karsilastirarak optimum degeri bulma
            if fonksiyonun_sonucu > hedef_fonksiyon(personal_best[i]):
                personal_best[i] = particles[i]

            if fonksiyonun_sonucu > global_best_fitness:
                global_best = particles[i]
                global_best_fitness = fonksiyonun_sonucu

            #ciktilari ekrana yazdırma
            text_islemler.insert("1.0","iterasyon: " + str(iterasyon+1) +
            "\tParçacık: "+str(i+1) +
            "\tFonksiyonun sonucu: " + str(hedef_fonksiyon(particles[i])) +
             "\tX degeri: "+str(particles[i])+ "\n")

    textbox_sonuc.delete(0, tk.END)
    textbox_sonuc.insert(0, str(global_best))

#GUI
root = tk.Tk()
root.title("PSO ile Matematiksel İfadeyi Maksimum Yapan X Değeri Bulma")

label_fonksiyon = tk.Label(root, text="Matematiksel İfade", font=('Cascadia Code',
15))
label_fonksiyon.pack()
textbox_fonksiyon = tk.Entry(root, width=50, font=('Cascadia Code', 15))
textbox_fonksiyon.pack()

label_minmax = tk.Label(root, text="X değeri aralığı", font=('Cascadia Code', 15))
label_minmax.pack()
textbox_min = tk.Entry(root, width=10, font=('Cascadia Code', 15))
textbox_min.pack()
textbox_max = tk.Entry(root, width=10, font=('Cascadia Code', 15))
textbox_max.pack()

label_iterasyon = tk.Label(root, text="İterasyon Sayısı", font=('Cascadia Code',
15))
label_iterasyon.pack()
textbox_iterasyon = tk.Entry(root, width=10, font=('Cascadia Code', 15))
textbox_iterasyon.pack()

buton_hesapla = tk.Button(root, text="Hesapla",command=pso, font=('Cascadia Code',
15))
buton_hesapla.pack()
```

```
label_sonuc = tk.Label(root, text="Fonksiyonun En Büyük Değerini Veren X Değeri",
font=('Cascadia Code', 15))
label_sonuc.pack()
textbox_sonuc = tk.Entry(root, width=50, font=('Cascadia Code', 15))
textbox_sonuc.pack()

text_islemler = tk.Text(root, width=800, font=('Cascadia Code', 15))
text_islemler.pack()

root.mainloop()
```

Program çalıştırıldığında kullanıcıyı basit tasarımlı bir GUI ekranı karşılamaktadır. Bu ekranda kullanıcıdan beklenen girdiler şunlardır:

- Sadece x değerine bağlı matematiksel bir fonksiyon
- X değerinin değerlendirileceği pozitif tam sayı aralığı
- İterasyon sayısı

Bu girdiler uygun formatta kullanıcıdan alınıp hesapla butonuna basıldıktan sonra "fonksiyon, iterasyon_sayisi, aralik_baslangic, aralik_bitis" değerleri tanımlanmış olur. Programın içerisinde tanımlanan statik değişkenler ise şunlardır:

- parcacık_sayisi
- w
- c1
- c2
- particles
- velocities
- personal_best_locals
- global_best_position
- global_best_fitness

Değişken tanımlamaları tamamlandıktan sonra PSO uygulaması için ilk adıma geçilmektedir. Bu adımda iterasyon sayısı kadar bir döngü ve bu döngünün içerisine belirlenen parçacık sayısı kadar bir döngü daha oluşturulmuştur. Bu sayede her bir iterasyonda her bir parçacık üzerinde işlem yapılabilir.

Döngü içerisinde yapılan ilk işlem PSO formülünde kullanılacak r1 ve r2 değerlerinin 0-1 aralığında olacak şekilde rastgele olarak tanımlanmasıdır. Bu aşamadan sonra PSO algoritmasının formülü için gereken tüm değerler tanımlanmış ve PSO formülü yazılmış olur.

Parçacıkların konumunun kullanıcıdan alınan başlangıç ve bitiş değerleri arasında kalması için bir sınırlandırma yapılmaktadır.

Parçacıklar girilen matematiksel ifadede x yerine konularak işleme sokulmaktadır ve işlem sonucu fonksiyonun_sonucu değişkenine atanmaktadır.

Elde edilen sonuç personal_best_locals değeri ile karşılaştırılmaktadır. Koşul bloğunda yapılan bu karşılaştırmada sonuç değeri personal_best_locals değerinden büyük ise yeni personal_best_locals değeri işleme alınan parçacığa eşit olur.

Aynı şekilde sonuç değeri global_best_position değeri ile bir koşul bloğunda karşılaştırılmaktadır. Sonuç değeri global_best_position değerinden de büyükse yeni global_best_position değeri işleme alınan parçacığa eşit olur ve fonksiyonun_sonucu, global_best_fitness değerine atanır.

Bu döngü iterasyon sayısı kadar tekrarlandığında global_best_fitness değeri kullanıcının girdiği fonksiyonun maksimum değerini, global_best_position değeri ise fonksiyonu maksimum yapan x değerini vermektedir.

Şekil 6'da örnek kod çıktısı bulunmaktadır.

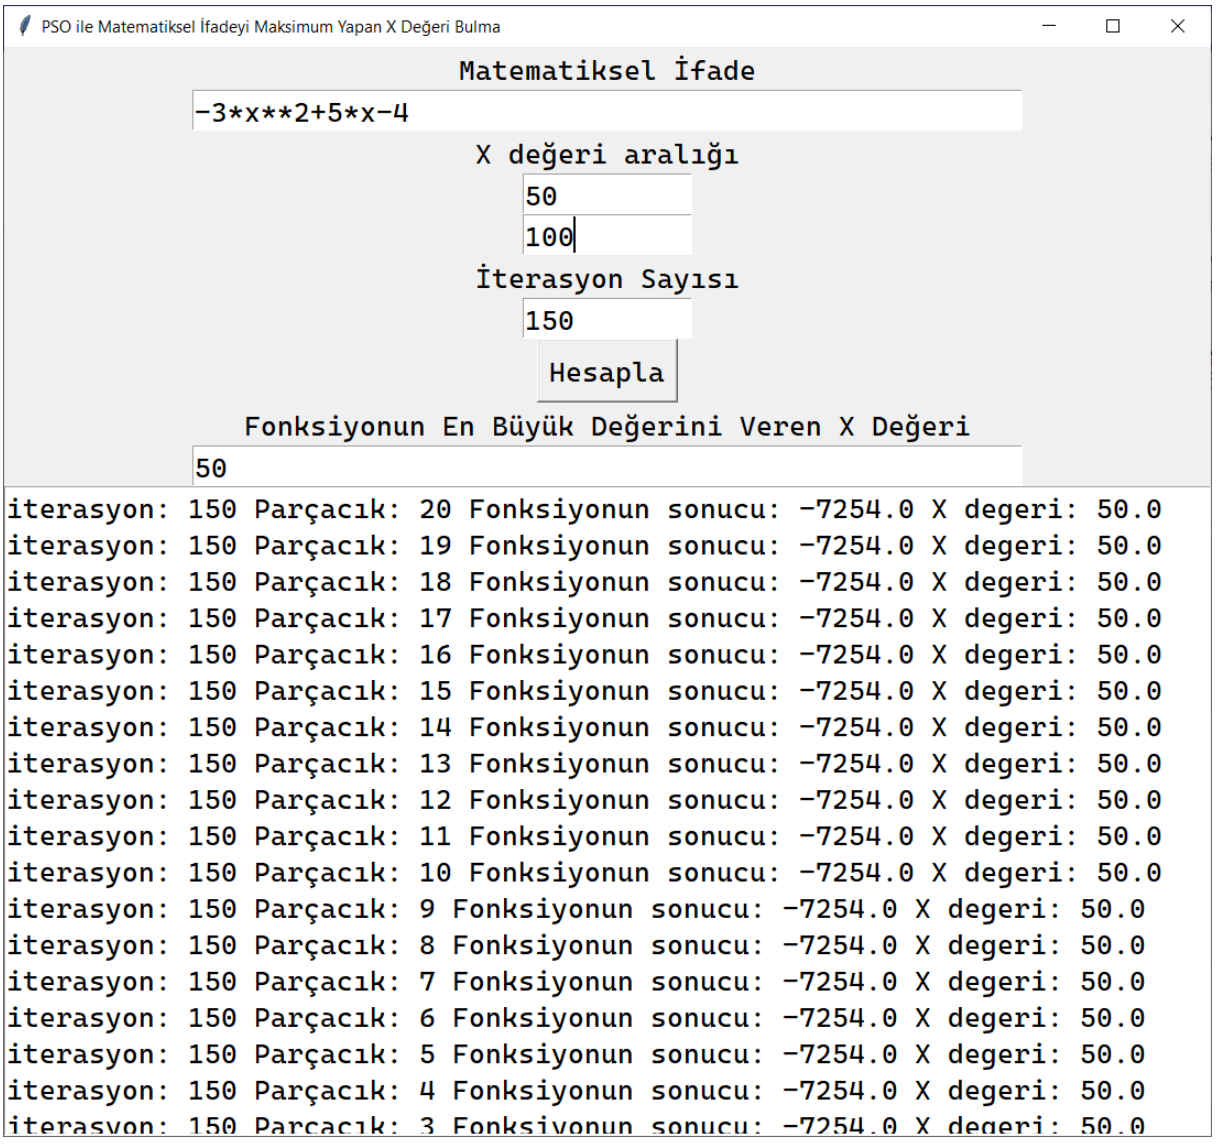

Şekil 6 / PSO Uygulaması Örnek Çıktısı

4. Kaynakça

1) Kılıç, G. (2023). Sıra bağımlı ilişkisiz paralel makine çizelgeleme problemi için yeni bir sezgisel algoritma önerisi.
2) ÖZSAĞLAM, M. Y., & ÇUNKAŞ, M. (2008). Optimizasyon problemlerinin çözümü için parçaçık sürü optimizasyonu algoritması. Politeknik Dergisi, 11(4), 299-305.
3) Özsağlam, M. Y. (2009). Parçacık sürü optimizasyonu algoritmasının gezgin satıcı problemine uygulanması ve performansının incelenmesi (Master's thesis, Selçuk Üniversitesi Fen Bilimleri Enstitüsü).
4) Demirci, H. (2014). Parçacık sürü optimizasyonu ve çoğalan sürü algoritmasının yüzey geri çatımı probleminde uygulanması ve karşılaştırılması (Doctoral dissertation, Sakarya Universitesi (Turkey)).
5) ERDOĞMUŞ, P. (2016). Doğadan esinlenen optimizasyon algoritmaları ve optimizasyon algoritmalarının optimizasyonu. Düzce üniversitesi bilim ve teknoloji dergisi, 4(1), 293-304.
6) Özer, S. (2017). Eşit olmayan hazırlama süreli tek makine toplam ağırlıklı gecikme problemlerinin parçacık ağırlıklı gecikme problemlerinin parçacık sürü optimizasyonu ile çözümü (Doctoral dissertation, Sakarya Universitesi (Turkey)).
7) Aytuğ, O. N. A. N. (2013). Metasezgisel yöntemler ve uygulama alanları. Çukurova Üniversitesi İktisadi ve İdari Bilimler Fakültesi Dergisi, 17(2), 113-128.
8) ORTAKCI, Y., & Göloğlu, C. (2012). Parçacık sürü optimizasyonu ile küme sayısının belirlenmesi.
9) ÖZSAĞLAM, M. Y., & ÇUNKAŞ, M. (2008). Optimizasyon problemlerinin çözümü için parçaçık sürü optimizasyonu algoritması. Politeknik Dergisi, 11(4), 299-305.
10) Çelik, Y., Yıldız, İ., & Karadeniz, A. T. (2019). Son Üç Yılda Geliştirilen Metasezgisel Algoritmalar Hakkında Kısa Bir İnceleme, Avrupa Bilim ve Teknoloji Dergisi, 463-477.
11) https://calismagruplari.itu.edu.tr/docs/librariesprovider5/default-document-library/ae2013ugurkusku.pdf?sfvrsn=0
12) https://medium.com/deep-learning-turkiye/par%C3%A7ac%C4%B1k-s%C3%BCr%C3%BC-optimizasyonu-pso-1402d4fe924a
13) https://biryazilimciningunlugu.wordpress.com/2017/05/16/metasezgisel-algoritmalar/